DEEP LEARNING · TRABALHO PRÁTICO · FRENTE 3.1 — MLP

Quais emendas parlamentares vão sair do papel?

Uma MLP para prever a execução financeira de emendas destinadas a municípios

Juliano Batista · Leandro Nascimento

Especialização em IA Aplicada — IFG · outubro de 2026

Prever, no momento da emenda, se ela terá execução financeira

Contexto

Quase metade das emendas destinadas a municípios não chega a ter execução financeira no ano.

Tarefa

Classificação binária: **executada = 1** se valor pago > 0 **ou** restos a pagar inscritos > 0.

Objetivo

Projetar, otimizar e avaliar uma MLP, comparando-a com referências clássicas e medindo custo × efetividade.

Utilidade: um escore de risco de não execução ajuda gestores municipais e órgãos de controle a priorizar o acompanhamento.

União pelo código IBGE do município

Emendas parlamentares
Portal da Transparência · emendas para municípios e para estados

Cidades IBGE
APIs Localidades + Cidades@ · 5.570 municípios, uma linha cada

→

INNER JOIN
chave: código IBGE do município, 7 dígitos

→

Dataset final da MLP

36.229

emendas municipais em 5.416 municípios (97%), cada uma com os indicadores do seu município

Código harmonizado
Cidades traz 6 dígitos; mantido o oficial de 7. Chaves convertidas para inteiro, preservando nulos.

Estaduais excluídas
Emendas para estados não têm código de município e saem na junção.

Anos de referência
Cada indicador usa o período mais recente do IBGE (ex.: Censo 2022, PIB per capita 2023).

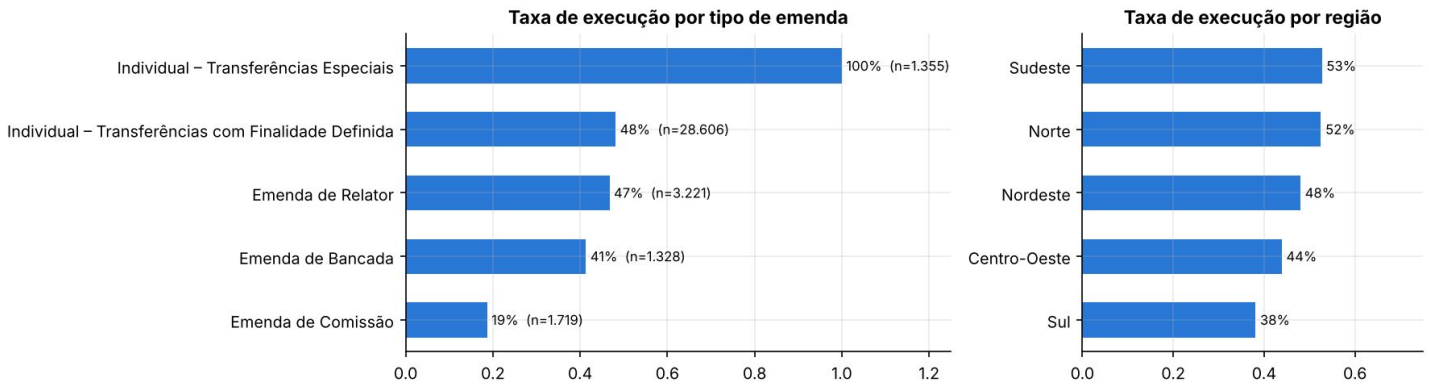
Emendas do Portal da Transparência + indicadores do IBGE

36.229
registros de emendas

5.416
municípios (97% do país)

10 + 25
categóricos + numéricos

48,3%
das emendas executadas



Poucos problemas; o principal cuidado foi evitar vazamento

Aspecto	O que encontramos	Tratamento
Valores ausentes	≤ 0,19% por coluna	Mediana (numéricas) e moda (categóricas)
Caudas longas	População, PIB e receitas	log1p antes da padronização
Outliers	Capitais e grandes municípios	Mantidos: são valores legítimos
Alta cardinalidade	313 ações, 149 programas	Categorias raras agrupadas
Vazamento	Empenhado, liquidado, pago	Removidos: são etapas da própria execução

Macro-F1 como métrica principal: pesa as duas classes por igual

Principal

Macro-F1: média do F1 das duas classes. Guia a busca de hiperparâmetros e a escolha do modelo.

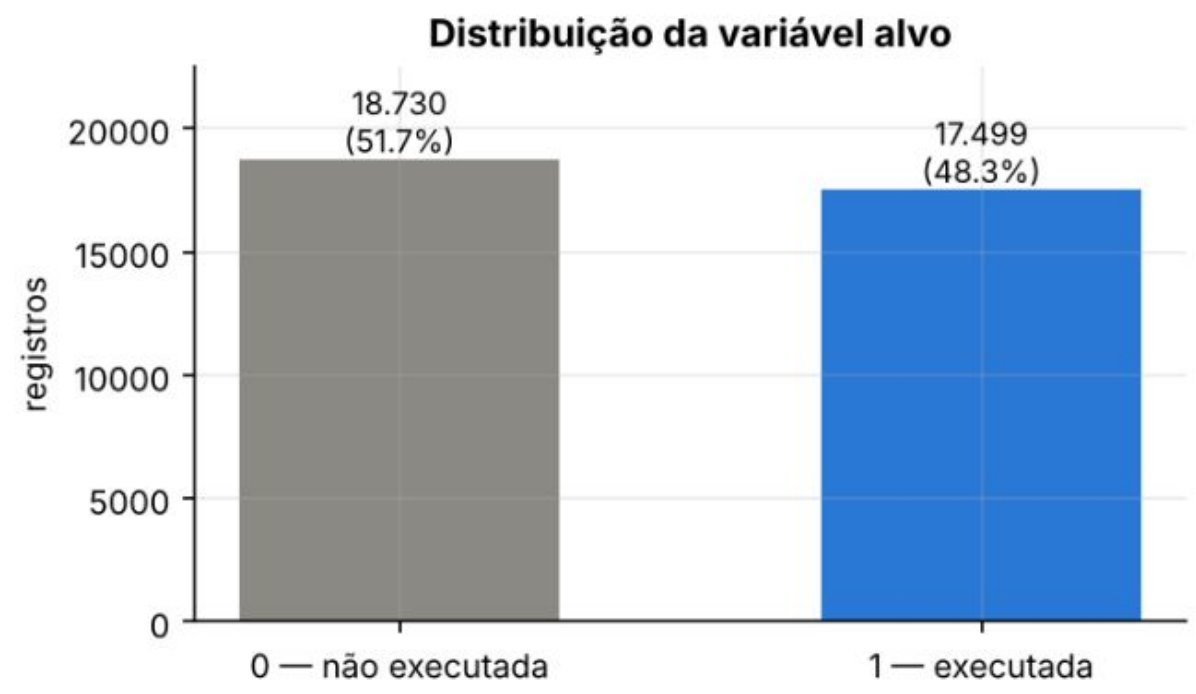
Complementares

Acurácia, Precisão e Recall.

Custo

Tempo de treino, tempo de inferência por amostra e número de parâmetros.

Distribuição da variável alvo



Mesmo com classes equilibradas, chutar "não executada" para tudo acerta 51,7%, mas tem Macro-F1 de só 0,34, porque nunca acerta uma executada. .

Divisão por município: o teste só tem municípios nunca vistos

Treino · 72%
25.867 registros
3.875 municípios

Validação · 14%
5.175 registros
749 municípios

Teste · 14%
5.187 registros
792 municípios

Por que agrupar

Os 25 indicadores se repetem em todas as emendas do município; numa divisão aleatória a rede poderia memorizá-lo.

Como

StratifiedGroupKFold: 48,3% de executadas nas três partes. Teste usado uma única vez, no fim.

De 35 atributos a 313 entradas, ajustado só no treino

18 numéricas assimétricas
mediana → log1p → padronização
18

7 numéricas
mediana → padronização
7

10 categóricas
moda → one-hot (raras e novas → "infrequente")
288

313
entradas da MLP

Um bloco oculto repetido N vezes, com saída sigmoide



Treinamento

Entropia cruzada binária, otimizador Adam, até 150 épocas, TensorFlow/Keras.

Regularização

Dropout, L2 nos pesos, BatchNorm e parada antecipada pela perda de validação, restaurando os melhores pesos.

Configurável

Uma só função gera todas as variantes: profundidade, largura, formato, ativação e regularização.

10 hiperparâmetros buscados com Optuna

Hiperparâmetro	Faixa	Melhor
Camadas	1 a 5	2
Neurônios	32 a 512	32
Formato	constante / funil	constante
Ativação	ReLU / ELU	ReLU
Dropout	0 a 0,5	0,26

Hiperparâmetro	Faixa	Melhor
L2	1e-6 a 1e-2 (log)	2,4e-5
BatchNorm	sim / não	sim
Taxa de aprendizado	1e-4 a 1e-2 (log)	0,0024
Lote	64 a 512	512
Paciência	5 / 10 / 20	20

Amostrador TPE + poda por mediana

Tentativas fracas encerradas cedo

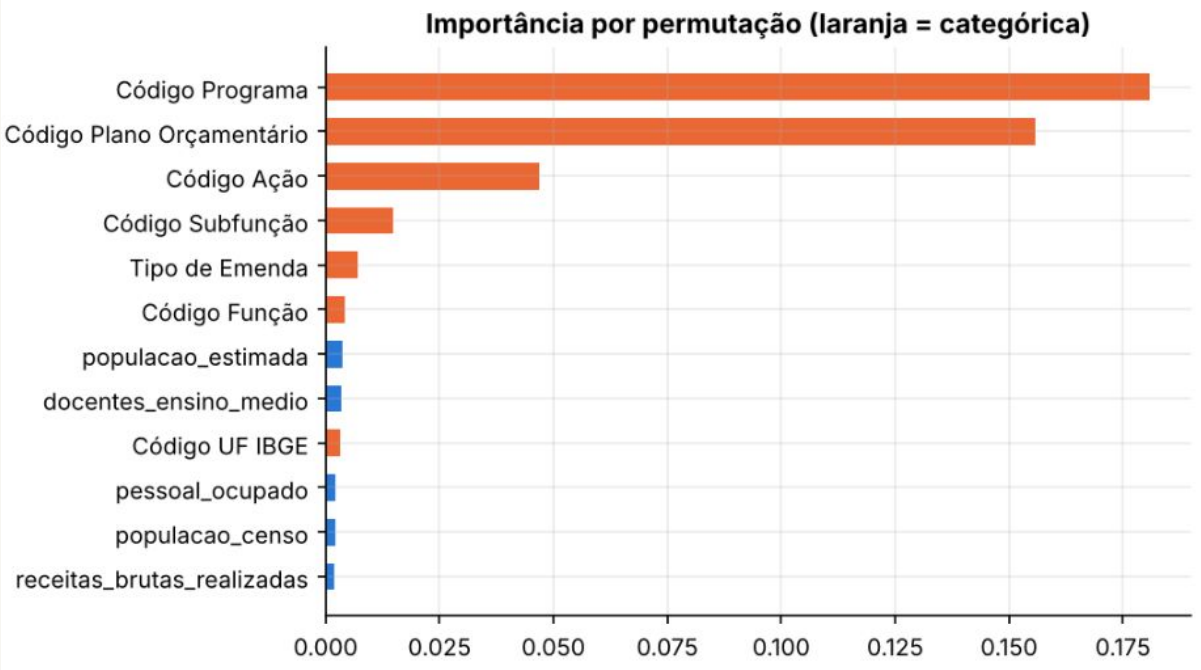
40 tentativas

26 completas, 14 podadas · 25 min em CPU

Objetivo

Macro-F1 na validação · melhor 0,887

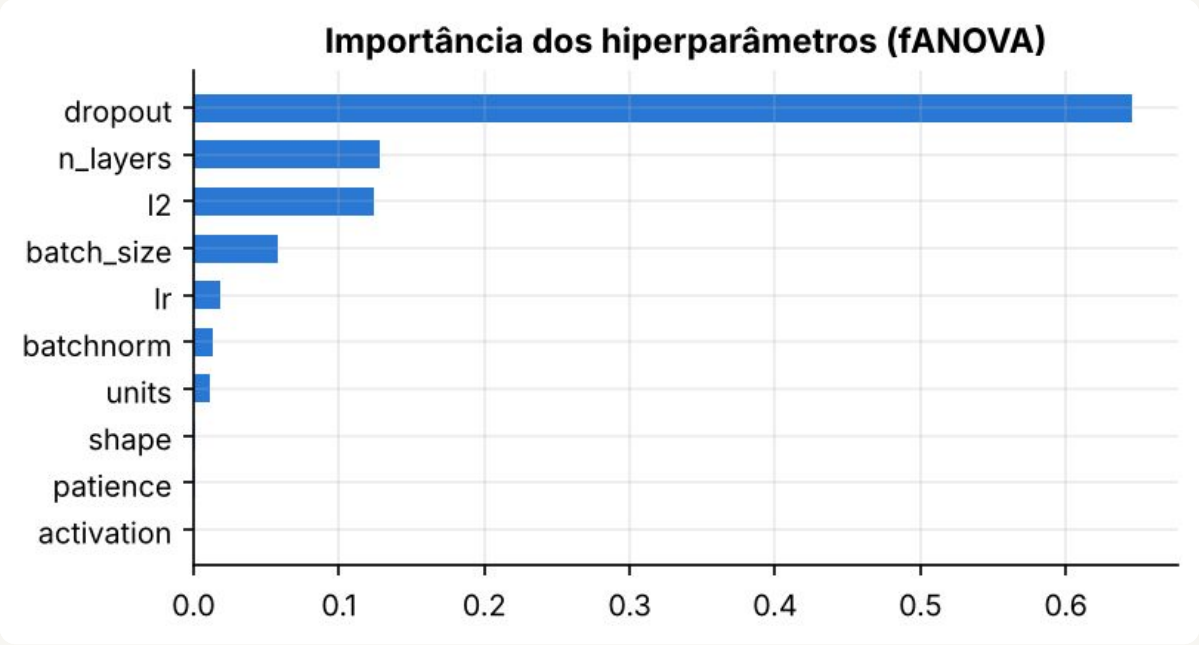
Peso dos parâmetros



87%

A rede decide quase só pela classificação orçamentária da emenda

Regularizar importa mais do que aumentar a rede



65%

da variação da Macro-F1 explicada pelo dropout

Depois vêm número de camadas (13%), L2 (12%) e lote (6%).

Taxa de aprendizado, neurônios, formato e ativação somam menos de 4%.

5.3 · TRÊS ARQUITETURAS PROMISSORAS × 5 SEMENTES (VALIDAÇÃO)

Empate técnico; escolhemos a compacta, 1×32

Arquitetura	Macro-F1 (média ± dp)	Parâmetros
A — Melhor Optuna (2×32)	0,8832 ± 0,0030	11.329
B — Compacta (1×32)	0,8842 ± 0,0015	10.177
C — Profunda regularizada (4×512)	0,8818 ± 0,0037	955.393

Por que B

Maior média e menor variação entre sementes, com menos parâmetros.

Diferenças pequenas

As três ficam dentro de 0,25 p.p., na ordem da variação entre sementes.

Grande não compensa

C tem 94 vezes mais parâmetros e treina 5,5 vezes mais devagar, sem ganho.

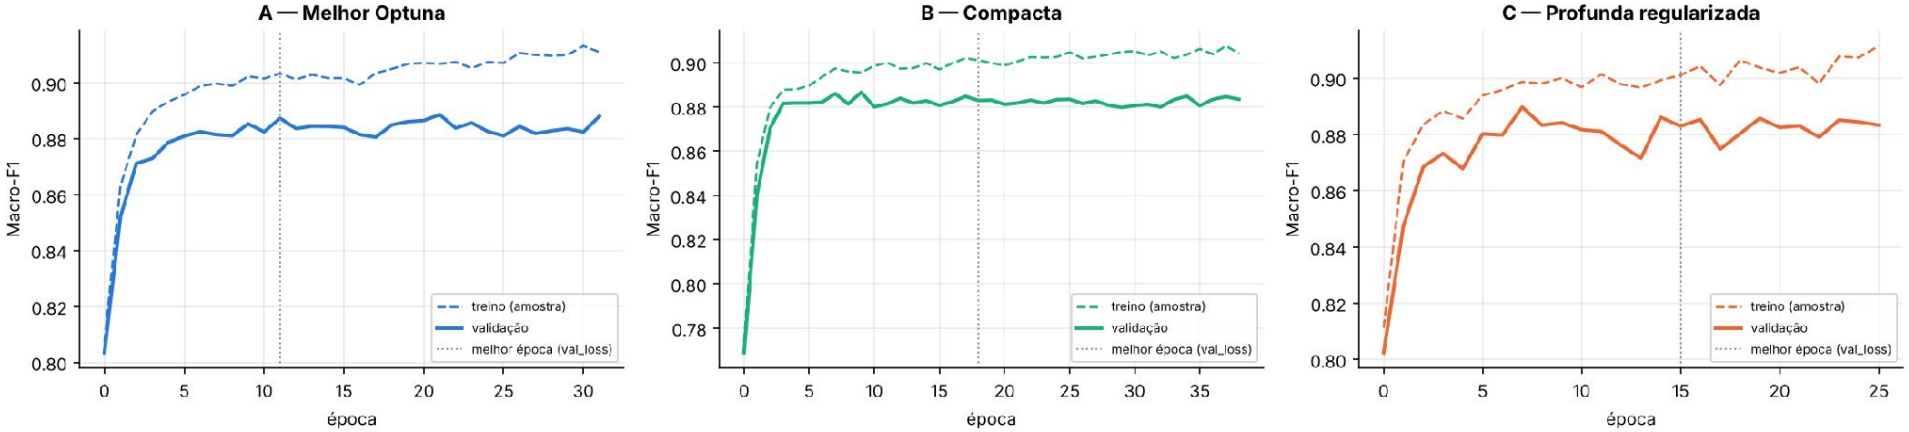
5.3 · COMPARAÇÃO DAS CONFIGURAÇÕES

A, B e C: mesma MLP, outras escolhas

	A — Melhor Optuna	B — Compacta	C — Profunda regularizada
Camadas × neurônios	2 × 32	1 × 32	4 × 512
Dropout	0,26	0,38	0,30
L2	2,4e-5	4,9e-6	1e-4
BatchNorm	sim	sim	sim
Taxa de aprendizado	0,0024	0,0016	0,0024
Lote	512	512	512
Paciência da parada	20	20	10
Parâmetros	11.329	10.177	955.393
De onde veio	melhor tentativa do Optuna	tentativa do Optuna com menos parâmetros, a até 0,5 p.p. da melhor	a maior rede testada + a regularização que mais reduziu o overfitting

5.3 · MACRO-F1 POR ÉPOCA — TREINO × VALIDAÇÃO

As três aprendem rápido e estabilizam perto de 0,88



A — Melhor Optuna

Validação em ~0,88 a partir da época 5; gap de 0,019.

B — Compacta

A curva mais estável; treino e validação andam juntos (gap 0,021).

C — Profunda regularizada

Validação oscila mais e o treino segue subindo: maior gap (0,028).

6 · AVALIAÇÃO FINAL NO TESTE (792 MUNICÍPIOS NUNCA VISTOS)

A MLP compacta supera as referências em ~1 p.p.

0,890

Macro-F1 da MLP B, o modelo escolhido na validação

Modelo (teste)	Macro-F1	Acurácia
MLP B — Compacta	0,890	0,890
MLP A — Melhor Optuna	0,891	0,891
MLP C — Profunda regularizada	0,884	0,885
Regressão logística	0,881	0,881
Gradient boosting	0,879	0,879
Classe majoritária	0,341	0,517

Erros equilibrados: a MLP B acerta 88,4% das não executadas e 89,7% das executadas. Limiar 0,51 escolhido na validação.

Pouca capacidade, muita regularização

Limitações

- Os códigos orçamentários mudam a cada PPA: a rede pode aprender quando a emenda foi feita.
- Emendas de comissão (classe rara): Macro-F1 cai para 0,778.
- Baixa granularidade dos dados orçamentários: informações mais detalhadas poderiam revelar padrões adicionais de execução das emendas.

Conclusões

- Uma MLP 1×32 (~10 mil parâmetros) atinge Macro-F1 0,890 em municípios nunca vistos.
- Capacidade não foi o gargalo; regularização foi decisiva.
- Programa, plano orçamentário e ação concentram 87% da importância dos atributos (41%, 35% e 11%); os indicadores municipais somam cerca de 6%.

Código: [link do GitHub] · Relatório técnico completo no repositório